



中国乳腺癌自然史参数选择的优化方法

尹娟¹, 王乐^{2,3}, 白晓宁⁴, 李燕婕², 王鑫², 张在坤⁵, 李炳照⁴, 李扬⁶,
石菊芳^{2*}, 李庆娜^{4*}

1. 北京理工大学管理与经济学院, 北京 100081;
2. 国家癌症中心国家肿瘤临床医学研究中心和中国医学科学院北京协和医学院肿瘤医院癌症早诊早治办公室, 北京 100021;
3. 浙江省肿瘤医院, 杭州 310022;
4. 北京理工大学数学与统计学院 MCAACI 北京市重点实验室和信息安全的数学理论与计算工信部重点实验室, 北京 100081;
5. 香港理工大学应用数学系, 香港 999077;
6. 中国医学科学院北京协和医学院医学信息研究所, 北京 100020

E-mail: juanyin@bit.edu.cn, wangle@zjcc.org.cn, 3120201449@bit.edu.cn, liyanjie97@163.com, wxph1221@163.com,
zaikun.zhang@polyu.edu.hk, li.bingzhao@bit.edu.cn, li.yang@imicams.ac.cn, shijf@cicams.ac.cn, qnl@bit.edu.cn

收稿日期: 2022-04-01; 接受日期: 2022-08-30; 网络出版日期: 2022-12-05; * 通信作者
国家自然科学基金 (批准号: 12071032 和 81773521) 资助项目

摘要 乳腺癌是女性最常见的恶性肿瘤之一. 为了提出有效的筛查策略并评估其效果, 一个基本且重要的步骤是在中国乳腺癌自然史模型中选择合适的参数, 即转移概率. 选择合理的转移概率有两个挑战. 首先, 由于乳腺癌的流行病学特性, 其他国家使用的转移概率不一定适用于中国. 其次, 可用的筛查样本数据很少, 这使得传统的基于统计的方法 (如极大似然估计法) 失效. 本文从优化角度提出一种乳腺癌自然史参数选择的方法, 基于公布的统计数据建立数学优化模型. 该模型的挑战在于目标函数高度非线性且无显式表达式, 本文提出一种坐标下降算法来处理这个挑战. 最后, 本文提出一种最佳匹配方法来估计每个转移概率的分布. 本文所提出的方法为进一步提出合理的中国乳腺癌筛查策略和分析乳腺癌的经济负担提供了坚实的基础.

关键词 乳腺癌 自然史 参数选择 黄金分割法 无导数法 坐标下降法

MSC (2020) 主题分类 90C56, 90C26, 90C10

1 引言

乳腺癌是全世界女性确诊率最高的癌症^[9]. 在中国, 乳腺癌是女性中最常见的癌症^[28]. 然而, 目前还没有针对中国女性的常规筛查计划. 为了提出合理的筛查策略并评估效果, 基本问题之一是, 在乳腺癌自然史模型中选择适合中国本土人群参数, 即转移概率. 有了精确的参数, 人们才能进一步研究乳腺癌的筛查模型, 并据此提出和评估有效的筛查策略.

英文引用格式: Yin J, Wang L, Bai X N, et al. An optimization approach for parameter selection in natural history of breast cancer in China (in Chinese). Sci Sin Math, 2023, 53: 895–913, doi: 10.1360/SCM-2022-0196

乳腺癌的自然史模型本质上是 Markov 过程, 以模拟乳腺癌中不同状态之间的关系. Markov 过程从健康状态开始, 终止于死亡. 乳腺癌自然史和筛查效果的研究可追溯到 20 世纪 60 年代 [7, 8, 15, 25, 27], 相关评价参见文献 [17, 24]. 自然史模型通常有两种类型: 一种基于个体, 称为个体 Markov 模型 [21, 30]; 另一种基于 Monte Carlo 模拟, 称为队列 Markov 模型 [13, 26]. 两者都涉及不同状态之间的转移概率, 所以建立有效的自然史模型的一个关键问题是找到合适的转移概率, 该转移概率要尽可能符合中国本土人群的实际情形. 为此, 在许多文献中, 传统的方法是根据一些统计规则建立优化模型, 如极大似然估计, 其中涉及从本国启动的筛查计划中获得的样本筛查数据 [4, 23]. 在发达国家, 如加拿大、日本和美国 [4, 26], 乳腺癌筛查项目已经进行了几轮. 因此, 有足够的样本数据可用于极大似然估计方法. 而另一种方法是在没有样本数据的情形下建立优化模型, 这主要是在西方国家开始提出筛查策略时所研究的 [1, 2, 25, 31]. 在软件方面, TreeAge¹⁾ 和 MISCAN^[11] 是两个最常用的平台, 它们是专门用于做疾病筛查分析的软件.

对于中国特定的乳腺癌自然史模型, 参数选择仍然存在两个挑战. 第一, 由于乳腺癌的流行病学特性, 其他国家文献中采用的参数不一定适用于中国 [28]. 其次, 在中国无法获得连续时间段的筛查样本数据, 这使得传统的基于样本的统计方法 (如极大似然估计 (maximum likelihood estimate, MLE) [4, 23]) 失败. 事实上, 在中国政府的支持下, 2012 年启动了中国城市癌症筛查项目 [6]. 该项目中包括乳腺癌筛查, 并且政府从项目中获得了样本数. 要使用基于样本的极大似然估计方法 [4, 23], 就需要连续地筛查样本数据, 这些数据可以与 2012 年的数据进行比较. 然而, 2012 年后没有自然筛查项目, 这使得极大似然估计方法无法实现. 事实上, 国家愿意开展进一步的筛查项目. 然而, 由于涉及大量预算, 我们需要确保拟议的筛查策略有效, 以避免浪费资金. 因此, 作为筛查的基线, 在开展进一步筛查项目之前, 必须确定乳腺癌自然史中适当的转移概率. 换言之, 必须在没有筛查数据的情形下得到适合中国乳腺癌的转移概率, 以便为中国筛查策略的设计提供指导. 最后, 虽然 TreeAge 和 MISCAN 适用于模拟乳腺癌的自然史, 但是它们都基于已知的转移概率, 想要通过 TreeAge 和 MISCAN 调整转移概率, 以找到最适合中国人口的最佳转移概率并不方便. 因此, 我们非常需要开发一个独立的软件包, 根据该软件包可以调整转移概率, 并从中选择最适合中国乳腺癌自然史的参数.

以上即为本文的研究动机. 我们有如下两个目标: (i) 在没有样本数据的情形下, 尝试在中国特定的乳腺癌自然史中找到合适的转移概率; (ii) 假设每个转移概率是来自 Beta 分布的随机变量, 尝试找出每个 Beta 分布中的参数.

根据这两个目标, 本文的贡献如下: (i) 基于 2016 年公布的统计数据²⁾ (发病率、死亡率和临床分期百分比), 本文提出一个优化模型, 以估计中国乳腺癌自然史模型中的转移概率. 与文献 [25] 不同, 本文的优化模型是基于乳腺癌自然史的 Markov 过程的数学描述建立的. (ii) 本文提出一种坐标下降法来处理具有界约束的高度非线性优化问题, 该问题的目标函数没有显式表达式. 每个子问题都采用黄金分割法求解, 并且该方法能够尽可能少地计算目标函数值. (iii) 本文提出一种最佳匹配方法来推导每个转移概率的概率分布中的参数. 最后, 通过数值实验验证该方法的有效性.

本文余下内容的结构如下. 第 2 节建立乳腺癌自然史的 Markov 过程的数学模型. 第 3 节提出乳腺癌自然史中参数选择的最小二乘优化模型. 第 4 节提出坐标下降法来解决具有界约束的最小二乘问题, 其中每个子问题都用黄金分割法求解. 第 5 节讨论获得每个转移概率的概率分布参数的最佳匹配方法. 第 6 节给出数值结果. 第 7 节给出最终结论.

1) TreeAge Software, Inc, Williamstown, Massachusetts

2) 国家肿瘤中心. 2016 年中国癌症年报. 北京: 人民医学出版社, 2019

2 乳腺癌自然史 Markov 过程的数学模型

2.1 Markov 过程

正如引言中提到的, 自然史模型主要有两种类型: 个体 Markov 模型和队列 Markov 模型. 因队列 Markov 模型涉及 Monte Carlo 模拟, 较复杂, 故本文研究相对简单的个体 Markov 模型 [3, 10, 22, 26]. 图 1(a) 总结了乳腺癌的自然史 [17], 由于导管上皮/不典型增生状态可能会转回至健康状态, 为简单起见, 本文不包括这种状态. 也就是说, 我们认为乳腺癌的自然史如图 1(b) 所示. 基于图 1(b), 相应的 Markov 过程如图 2 所示. 这里没有描绘从状态到自身的转变, 当然确实有这样到自身的转变. 总共有 $s = 15$ 个状态, 如图 2 所示, 标记为 $1, 2, \dots, 15$. 个体 Markov 过程按以下方式运行. 对于从 Y_1 岁开始且健康的 r 个人, 他们每年都会持续一个时间步长, 直到死亡或到 Y_2 岁, 以先发生者为准.

2.2 数学描述

为了从数学上描述乳腺癌自然史的 Markov 模型, 我们使用 $i \rightarrow j$ 表示从状态 i 到状态 j 的转移. 传统的符号是转移矩阵 $P = (p_{i,j}) \in \mathbb{R}^{s \times s}$, 其中 $p_{i,j}$ 表示从状态 i 到状态 j 的转移概率.

如图 3 所示, 由于乳腺癌自然史的特殊结构, 大多数转移概率为零 (白色). 对于非零转移概率 (以灰色标记), P 中总共有 45 个非零转移概率. 按照以下方式对它们进行分组.

对于每个状态 i , 其转移到的状态表示为 N_i , 并在表 1 中汇总. 例如, 状态 i 转移到的状态是 $\{1, 2, 3, 14\} := N_1$, 分别是健康、临床前小叶原位癌、临床前导管原位癌和其他原因导致的死亡, 如




图 1 (网络版彩图) 乳腺癌自然史. (a) 文献 [17] 中的乳腺癌自然史; (b) 本文中的乳腺癌自然史




图 2 乳腺癌自然史的 Markov 模型

图 4(a) 所示. 此外, 根据转移概率的性质, 有以下关系:

$$\sum_{j \in N_i} p_{i,j} = 1, \quad i = 1, 2, \dots, 13. \quad (2.1)$$

类似地, 设 M_j 表示可能转移到状态 j 的状态. 例如, 对于状态 4, $M_4 = \{2, 3, 4\}$; 对于状态 15, $M_{15} = \{8, 9, 10, 11, 12, 13\}$, 如图 4(b) 和 4(c) 所示. 表 2 显示了每个状态 j 的 M_j 的详细信息.

考虑年龄段为 Y_1 至 Y_2 的人群, 令 $A = (A_{i,j}) \in \mathbb{R}^{s \times l}$, 其中 $l = Y_2 - Y_1 + 1$, 并且 $A_{i,j}$ 表示在状态 i 且年龄为 $Y_1 + j - 1$ 的总人数. 如上文所述, r 是 Y_1 岁 (起始年龄) 时处于状态 i (健康) 的健康人数, 即

$$A_{1,1} = r. \quad (2.2)$$

当年龄为 $Y_1 + k - 1$ 时, 从邻近状态 $j \in N_i$ 转移到状态 i 的人数为 $A_{i,k} p_{i,j}$. 年龄为 $Y_1 + k$ 且处于状态 h 的人数为从状态 M_h 转移过来的总人数, 即

$$A_{h,k+1} = \sum_{j \in M_h} A_{j,k} p_{j,h}. \quad (2.3)$$




图 3 转移概率矩阵 P

表 1 状态 i 和 i 可能转移到的相应状态 N_i

状态 i	N_i	状态 i	N_i
1	{1, 2, 3, 14}	8	{8, 14, 15}
2	{2, 4, 8, 14}	9	{9, 14, 15}
3	{3, 4, 9, 14}	10	{10, 14, 15}
4	{4, 5, 10, 14}	11	{11, 14, 15}
5	{5, 6, 11, 14}	12	{12, 14, 15}
6	{6, 7, 12, 14}	13	{13, 14, 15}
7	{7, 13, 14}		

2.3 发病率、死亡率和临床分期百分比的计算

基于 (2.2) 和 (2.3), Markov 过程运转能够得到 A . 根据 A , 通过以下公式计算发病率 (IR)、死亡




图 4 部分 Markov 过程图示

表 2 状态 j 和可能转移到 j 的相应状态 M_j

状态 j	M_j	状态 j	M_j
1	{1}	9	{3, 9}
2	{1, 2}	10	{4, 10}
3	{1, 3}	11	{5, 11}
4	{2, 3, 4}	12	{6, 12}
5	{4, 5}	13	{7, 13}
6	{5, 6}	14	{1, 2, ..., 13}
7	{6, 7}	15	{8, 9, ..., 13}
8	{2, 8}		

率 (MR) 和临床分期百分比 (PC):

$$\hat{\alpha}_i = \frac{\text{第 } i \text{ 岁时新发病人数}}{\text{第 } i \text{ 岁存活人数} - \text{第 } i-1 \text{ 岁末健康的人数}}, \quad i = Y_1, \dots, Y_2, \quad (2.4)$$

$$\hat{\beta}_i = \frac{\text{第 } i \text{ 岁时死于乳腺癌的人数}}{\text{第 } i \text{ 岁存活人数}}, \quad i = Y_1, \dots, Y_2, \quad (2.5)$$

$$\gamma_i = \frac{\text{临床 } i \text{ 阶段的人数}}{\text{所有临床个体的人数}} \times 100, \quad i = 0, \text{I, II, III, IV}, \quad (2.6)$$

其中, $\hat{\alpha}_i$ 和 $\hat{\beta}_i$ 分别表示年龄 i 的 IR 和 MR , γ_i 表示所有临床个体的临床 i 阶段的分期百分比.

以 5 年为年龄段, 共有 m 个年龄阶段, 即 $m = (Y_2 - Y_1 + 1)/5$. 对于每个阶段, 通过分别取 5 年的平均 IR 和 MR 来计算 IR 和 MR , 即 $\alpha \in \mathbb{R}^m$ 和 $\beta \in \mathbb{R}^m$ 由

$$\alpha_k = \frac{1}{5} \sum_{i=0}^4 \hat{\alpha}_{Y_1+5(k-1)+i}, \quad \beta_k = \frac{1}{5} \sum_{i=0}^4 \hat{\beta}_{Y_1+5(k-1)+i}, \quad k = 1, 2, \dots, m$$

计算得出.

注 2.1 当计算 (2.4)–(2.6) 时, 按照以下方式对每个 $A_{i,j}$ 进行四舍五入:

$$\begin{cases} \lfloor A_{i,j} \rfloor, & \text{如果 } A_{i,j} < 1.5, \\ \lceil A_{i,j} \rceil, & \text{如果 } A_{i,j} \geq 1.5, \end{cases}$$

其中, $\lfloor \cdot \rfloor$ 表示小于或等于 $A_{i,j}$ 的最大整数, $\lceil \cdot \rceil$ 表示大于或等于 $A_{i,j}$ 的最小整数.

上述过程总结在图 5 中. 使用转移矩阵 P 和个体数量 r , 可以运行 Markov 过程以获得 A , 其中 A 中包含每个年龄和每个状态的个体数量. 基于 A 中的信息, 通过 (2.4)–(2.6) 计算得到 IR 、 MR 和 PC .




图 5 Markov 过程图示: 缩小

3 最小二乘模型

如上所示, 一旦提供了转移概率, 就可以计算 IR 、 MR 和 PC . 为了找到最佳转移概率, 以使所得 IR 、 MR 和 PC 尽可能与 2016 年的相应观测数据 (表示为 $\widehat{IR}$ 、 $\widehat{MR}$ 和 $\widehat{PC}$)²⁾ 相匹配, 一个自然的方法是建立优化模型. 本节提出以下优化模型以找到最佳转移概率:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{s.t.} \quad & d \leq x \leq c, \end{aligned} \quad (3.1)$$

其中 x 是要寻找的转移概率向量, $d \in \mathbb{R}^n$ 和 $c \in \mathbb{R}^n$ 分别是下界和上界, 它们将在后文中给定. 最后, 逐一分析以下关键因素: 决策变量、目标和约束.

3.1 决策变量

在我们的模型中, 与文献 [9] 类似, 取年龄从 $Y_1 = 20$ 到 $Y_2 = 89$, 模拟 $r = 10^5$ 人. 因此, 总共有 $q = 14$ 个年龄段. 回顾第 2 节的分析, 不同状态之间总共有 $s = 15$ 个状态和 45 个非零转移概率. 进一步对转移概率作出以下假设.

假设 3.1 对于 $i \rightarrow j$ 的转移, 假设年龄段 l 的转移概率不变, 表示为 $p_{i,j}^l$.

假设 3.2 由于状态 2 (小叶原位癌) 和状态 3 (导管原位癌) 之间的特殊关系, 假设对于 $1 \rightarrow 2$ 和 $1 \rightarrow 3$ 的转移概率满足

$$p_{1,2}^l = 0.18p_{1,3}^l, \quad l = 1, 2, \dots, 14. \quad (3.2)$$

此外, $8 \rightarrow 15$ 和 $9 \rightarrow 15$ 的转移概率相等, 即假设

$$p_{8,15}^l = p_{9,15}^l, \quad l = 1, 2, \dots, 14. \quad (3.3)$$

类似地, $2 \rightarrow 4$ 和 $3 \rightarrow 4$ 的转移概率也是成比例的, 即假设

$$p_{2,4}^l = 1.2p_{3,4}^l, \quad l = 1, 2, \dots, 14. \quad (3.4)$$

假设 3.3 为了简化分析, 假设从临床前期到临床期对应阶段的转移概率已知, 以及由其他原因导致的死亡率已知, 即已知

$$p_{2,8}^l, p_{3,9}^l, p_{4,10}^l, p_{5,11}^l, p_{6,12}^l, p_{7,13}^l, p_{8,15}^l, \quad l = 1, 2, \dots, 14 \quad (3.5)$$

和

$$p_{i,14}^l, \quad i = 1, 2, \dots, 13, \quad l = 1, 2, \dots, 14. \quad (3.6)$$

注 3.1 由假设 3.1-3.3 知, 转移概率 $p_{7,7}^l$ 、 $p_{8,8}^l$ 和 $p_{9,9}^l$ ($l = 1, 2, \dots, 14$) 也是已知的, 因为有

$$p_{7,7}^l + p_{7,13}^l + p_{7,14}^l = 1, \quad l = 1, 2, \dots, 14, \quad (3.7)$$

$$p_{i,i}^l + p_{i,14}^l + p_{i,15}^l = 1, \quad i = 8, 9, \quad l = 1, 2, \dots, 14. \quad (3.8)$$

如图 6 所示, 依据假设 3.1-3.3, 在 P 中由 $\checkmark$ 标记的转移概率已知并且固定. 因此, 独立转移概率的数量从 rq 进一步减少到 $(r-6)q = 126$. 用 $x \in \mathbb{R}^{126}$ 表示未知的转移概率, 它是 (3.1) 中决策变量的向量. 此外, 假设 x 可以如下划分:

$$x = \begin{bmatrix} \bar{x}_1 \\ \vdots \\ \bar{x}_{r-6} \end{bmatrix} \in \mathbb{R}^{(r-6)q}, \quad \bar{x}_i \in \mathbb{R}^q, \quad (3.9)$$

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
1			$\bar{x}_1$												$\checkmark$
2								$\checkmark$							$\checkmark$
3									$\checkmark$						$\checkmark$
4										$\checkmark$					$\checkmark$
5											$\checkmark$				$\checkmark$
6												$\checkmark$			$\checkmark$
7								$\checkmark$					$\checkmark$	$\checkmark$	
8								$\checkmark$						$\checkmark$	$\checkmark$
9									$\checkmark$					$\checkmark$	$\checkmark$
10														$\checkmark$	$\bar{x}_6$
11														$\checkmark$	$\bar{x}_7$
12														$\checkmark$	$\bar{x}_8$
13														$\checkmark$	$\bar{x}_9$
14															
15															

图 6 P 中不同的非零部分: $\checkmark$ 表示可用, $\bar{x}_i$ 表示变量, 灰色用 $\bar{x}_i$ 表示

表 3 x 中的每个块所代表的状态转移概率

$\bar{x}_1$	$\bar{x}_2$	$\bar{x}_3$	$\bar{x}_4$	$\bar{x}_5$	$\bar{x}_6$	$\bar{x}_7$	$\bar{x}_8$	$\bar{x}_9$
$1 \rightarrow 3$	$3 \rightarrow 4$	$4 \rightarrow 5$	$5 \rightarrow 6$	$6 \rightarrow 7$	$10 \rightarrow 15$	$11 \rightarrow 15$	$12 \rightarrow 15$	$13 \rightarrow 15$

其中每个块 $\bar{x}_i$ 表示表 3 中所示的转移概率. 例如, $\bar{x}_1$ 表示从状态 1 到状态 3 的转移概率, $\bar{x}_1$ 中的第 j 个分量表示为 $(\bar{x}_1)_j$, 表示在年龄段 j 从状态 1 向状态 3 的转移概率. 有时, 也使用 x 中的一个单一的转移概率 x_l 来表示 x 中的一个元素, 表示在某个年龄段从一个特定状态到另一个状态的转移概率. 图 6 中还展示了转移矩阵 P 的变量 x 的相应位置.

注 3.2 注意, 我们没有将 $p_{i,i}^l$ ($i \neq 7, 8, 9$) 作为变量. 原因是, 根据 (2.1) 有以下条件:

$$\sum_{j \in N_i} p_{i,j}^l = 1, \quad l = 1, 2, \dots, 14, \quad i = 1, 3, 4, 5, 6, 10, 11, 12, 13. \quad (3.10)$$

因此, $p_{i,i}^l$ 可以用下列方式表示:

$$p_{i,i}^l = 1 - \sum_{j \in N_i, j \neq i} p_{i,j}^l, \quad l = 1, 3, 4, \dots, 14, \quad i = 1, 3, 4, 5, 6, 10, 11, 12, 13. \quad (3.11)$$

具体地, 根据 x 的定义和 (3.2)–(3.6), 对于 $l = 1, 2, \dots, 14$, 有

$$p_{1,1}^l = 1 - 1.18\bar{x}_1^l - p_{1,14}^l, \quad (3.12)$$

$$p_{2,2}^l = 1 - 1.2\bar{x}_2^l - p_{2,8}^l - p_{2,14}^l, \quad (3.13)$$

$$p_{3,3}^l = 1 - \bar{x}_2^l - p_{3,9}^l - p_{3,14}^l, \quad (3.14)$$

$$p_{4,4}^l = 1 - \bar{x}_3^l - p_{4,10}^l - p_{4,14}^l, \quad (3.15)$$

$$p_{5,5}^l = 1 - \bar{x}_4^l - p_{5,11}^l - p_{5,14}^l, \quad (3.16)$$

$$p_{6,6}^l = 1 - \bar{x}_5^l - p_{6,12}^l - p_{6,14}^l, \quad (3.17)$$

$$p_{10,10}^l = 1 - p_{10,14}^l - \bar{x}_6^l, \quad (3.18)$$

$$p_{11,11}^l = 1 - p_{11,14}^l - \bar{x}_7^l, \quad (3.19)$$

$$p_{12,12}^l = 1 - p_{12,14}^l - \bar{x}_8^l, \quad (3.20)$$

$$p_{13,13}^l = 1 - p_{13,14}^l - \bar{x}_9^l. \quad (3.21)$$

因此, 通过 (3.12)–(3.21), $p_{i,i}^l$ ($i = 1, 3, 4, 5, 6, 10, 11, 12, 13$) 均可以用 x 表示.

如图 6 所示, 灰色部分可由决策变量 x 表示. 因此, x 可以完全代表乳腺癌自然史的 Markov 模型中的转移概率.

3.2 目标函数

在目标函数方面, 我们有 2016 年公布的统计数据²⁾, 即发病率、死亡率和临床分期百分比如表 4 所示, 分别表示为 $\widehat{IR}$ 、 $\widehat{MR}$ 和 $\widehat{PC}$. 一个自然的想法是, 找到 x , 使得 IR 、 MR 和 PC 的结果尽可能与相应的 $\widehat{IR}$ 、 $\widehat{MR}$ 和 $\widehat{PC}$ 相匹配. 由此得到以下目标函数:

$$f(x) = \lambda_1 L(\alpha(x) - \widehat{IR}) + \lambda_1 L(\beta(x) - \widehat{MR}) + \lambda_3 L(\gamma(x) - \widehat{PC}), \quad (3.22)$$

其中, $\alpha(x)$ 、 $\beta(x)$ 和 $\gamma(x)$ 表示 IR 、 MR 和 PC 的计算与 x 有关, $L(\cdot)$ 是损失函数. 它也可以被视为一种测量统计数据和 x 生成的数据之间差异的方法. 例如, 它可以选择 l_1 损失函数 $\|\cdot\|_1$ 和 l_2 损失函数 $\|\cdot\|_2^2$. 规定参数 $\lambda_i > 0$ ($i = 1, 2, 3$) 为权重参数, 用于平衡 3 项之间的权重.

表 4 2016 年中国的发病率、死亡率和临床分期百分比²⁾

年龄	发病率/100,000	死亡率/100,000	状态	临床阶段的百分比 ×100
20~24	1.13	0.14	0	3.6
25~29	6.17	0.69	I	15.6
30~34	16.52	2.46	II	54.7
35~39	31.59	3.93	III	22.8
40~44	62.15	8.17	IV	3.3
45~49	84.86	12.61		
50~54	106.36	20.98		
55~59	98.41	20.82		
60~64	110.80	27.78		
65~69	91.95	25.75		
70~74	83.12	28.47		
75~79	79.19	39.20		
80~84	69.69	50.84		
85~89	48.85	56.82		

3.3 约束

由于 x 表示转移概率, 因此 x 的基本约束是 $0 \leq x \leq 1$. 此外, 注意 $p_{i,i}^l \in [0, 1]$, 其中 $p_{i,i}^l$ ($i = 1, 3, 4, 5, 6, 10, 11, 12, 13$) 由 (3.12)–(3.21) 给出. 我们有以下约束: 对于 $l = 1, 2, \dots, 14$, 有

$$\begin{aligned}
&0 \leq x \leq 1, \\
&1 - 1.18\bar{x}_1^l - p_{1,14}^l \geq 0, \\
&1 - 1.2\bar{x}_2^l - p_{2,8}^l - p_{2,14}^l \geq 0, \\
&1 - \bar{x}_2^l - p_{3,9}^l - p_{3,14}^l \geq 0, \\
&1 - \bar{x}_3^l - p_{4,10}^l - p_{4,14}^l \geq 0, \\
&1 - \bar{x}_4^l - p_{5,11}^l - p_{5,14}^l \geq 0, \\
&1 - \bar{x}_5^l - p_{6,12}^l - p_{6,14}^l \geq 0, \\
&1 - p_{10,14}^l - \bar{x}_6^l \geq 0, \\
&1 - p_{11,14}^l - \bar{x}_7^l \geq 0, \\
&1 - p_{12,14}^l - \bar{x}_8^l \geq 0, \\
&1 - p_{13,14}^l - \bar{x}_9^l \geq 0.
\end{aligned}$$

设 $c \in \mathbb{R}^{126}$ 和 $d \in \mathbb{R}^{126}$ 具有与 x 相同的划分, 即

$$\begin{aligned}
d &= (\bar{d}_1^T, \dots, \bar{d}_9^T)^T, \\
c &= (\bar{c}_1^T, \dots, \bar{c}_9^T)^T.
\end{aligned}$$

上述不等式通过以下方式给出了 x 的下界 d 和上界 c , 即对于 $l = 1, 2, \dots, 14$, 有

$$\bar{d}_1^l = 0.1\bar{p}_{1,3}^l, \quad \bar{d}_i^l = 0.1\bar{p}_{i+1,i+2}^l, \quad i = 2, 3, 4, 5, \quad (3.23)$$

$$\bar{d}_6^l = 0.1\bar{p}_{10,15}^l, \quad \bar{d}_7^l = \min\{0.1\bar{p}_{11,15}^l, 1.5\bar{p}_{10,15}^l\}, \quad (3.24)$$

$$\bar{d}_8^l = \min\{0.1\bar{p}_{12,15}^l, 2.5\bar{p}_{11,15}^l\}, \quad \bar{d}_9^l = \min\{0.1\bar{p}_{13,15}^l, 2.5\bar{p}_{12,15}^l\}, \quad (3.25)$$

$$\bar{c}_1^l = \frac{1-p_{1,14}^l}{1.18}, \quad \bar{c}_2^l = \min\left\{\frac{1-p_{2,8}^l-p_{2,4}^l}{1.2}, \frac{1-p_{2,14}^l-p_{2,8}^l}{2}\right\}, \quad (3.26)$$

$$\bar{c}_3^l = 1-p_{4,10}^l-p_{4,14}^l, \quad \bar{c}_4^l = 1-p_{5,11}^l-p_{5,14}^l, \quad \bar{c}_5^l = 1-p_{6,12}^l-p_{6,14}^l, \quad (3.27)$$

$$\bar{c}_i^l = \min\{1-p_{(i+2),14}^l, 1.1p_{i+5,14}^l\}, \quad i = 6, 7, 8, \quad (3.28)$$

$$\bar{c}_9^l = 1-p_{13,14}^l, \quad (3.29)$$

其中 $\bar{p}$ 是已知的经验转移概率. 最后, 得出以下优化问题:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) = \lambda_1 L(\alpha(x) - \widehat{IR}) + \lambda_2 L(\beta(x) - \widehat{MR}) + \lambda_3 L(\gamma(x) - \widehat{PC}) \\ \text{s.t.} \quad & d \leq x \leq c. \end{aligned} \quad (3.30)$$

4 数值算法

本节讨论求解 (3.30) 的数值算法. 对于给定的转移概率 x , 通过运行 Markov 过程获得函数值 $f(x)$, 因此很难写出 $f(x)$ 的显式形式. 如图 7 所示, 计算 $f(x)$ 可以被视为一个黑箱. 由于潜在的 Markov 过程, 优化问题 (3.30) 在以下 3 方面不同于传统优化问题: (i) $f(x)$ 的显式形式不可用; (ii) 目标函数 f 是非凸和高度非线性的; (iii) 函数值的计算耗时.

在设计求解 (3.30) 的算法时, 上述的 3 个事实导致了以下挑战: (i') 传统的基于梯度的方法不适用; (ii') 可能有许多局部极小值, 很难找到全局极小值; (iii') 在求解 (3.30) 时, 应减少计算函数值的次数.

事实上, 一种可能的方法是应用无导数方法^[5] (www.pdf0.net). 无导数方法是处理梯度不可用或不存在的问题所使用的优化方法. 由 Powell^[19,20] 提出的著名无导数软件包 pdf0 包含无导数解算器 BOBYQA^[19] 和 LINCOA^[20], 它们都可以处理具有约束的非线性优化问题. 然而, 通过探索问题 (3.30) 中的特殊结构, 也可以为 (3.30) 设计有效的算法. 下文提出了针对 (3.30) 特殊结构的坐标下降法.

4.1 坐标下降法

坐标下降法是处理优化问题的常用方法^[29], 特别是对于实际应用中产生的非凸问题. 坐标下降法的思想是, 在每次迭代中更新一个坐标, 同时固定其余变量, 从而使生成的子问题更容易处理. 对于问题 (3.30), 由于挑战 (i')–(iii'), 我们选择使用坐标下降法. 注意, x 中所有分量对函数值 f 都有贡献, 我




图 7 $f(x)$ 的计算

们需要在一轮中更新所有分量. 换言之, 对于每个周期, 我们对 x 的索引按照一定的顺序更新 x 中的所有分量. 然后, 进入另一轮, 重复这个过程. 算法 1 演示了坐标下降法的框架.

算法 1 坐标下降法框架

- S1 初始化: 初始点 x^0 , 误差 $\epsilon > 0$, $k := 0$.
 S2 对于每一轮 k , 从 x^k 开始, 按照某种顺序更新 x 的组件以获得输出 x^{k+1} .
 S3 如果 $f(x^k) - f(x^{k+1}) < \epsilon$, 停止; 否则, $k := k + 1$, 转到 S2.
-

对于步骤 S1, 给定初始点, 表示为 $y^0 \in \mathbb{R}^n$; 对于分量 y_j , 在内部第 k 次迭代, 表示

$$y_{-j}^k = (y_1^k, \dots, y_{j-1}^k, y_{j+1}^k, \dots, y_n^k) \in \mathbb{R}^{n-1}.$$

通过以下方式更新 y_j :

$$y_j^{k+1} := \arg \min_{y_j \in [d_j, c_j]} g^{k,j}(y_j) := f(y_j, y_{-j}^k). \quad (4.1)$$

设

$$y_l^{k+1} = y_l^k, \quad l \neq j. \quad (4.2)$$

然后通过 (4.1) 和 (4.2) 获得下一次迭代 y^{k+1} . 步骤 S2 中更新 x 分量的顺序, 可能会对函数值产生很大影响. 因此, 选择一种有效的方式进行更新是很重要的. 注意, 由于 x 的特殊结构, 对于每块 i , 我们将 $\bar{x}_i$ 中的元素从年龄段 1 更新到年龄段 q , 即 $(\bar{x}_i)_1, \dots, (\bar{x}_i)_{14}$. 所以唯一需要决定的顺序是更新块的顺序. 我们选择以下两种方法来更新块. 一种是自然升序:

$$(\mathcal{O}_1) \quad 1 \rightarrow 3 \rightarrow 4 \rightarrow 5 \rightarrow 6 \rightarrow 10 \rightarrow 11 \rightarrow 12 \rightarrow 13. \quad (4.3)$$

另一种是特殊的顺序:

$$(\mathcal{O}_2) \quad 5 \rightarrow 6 \rightarrow 1 \rightarrow 3 \rightarrow 4 \rightarrow 10 \rightarrow 11 \rightarrow 12 \rightarrow 13. \quad (4.4)$$

特殊的顺序 $\mathcal{O}_2$ 是由于 $\bar{x}_5$, 即 $p_{6,7}$ 是乳腺癌自然史的 Markov 过程中的关键转移概率, 相对其他转移概率更加重要.

坐标下降法的细节总结如下. 在算法 2 中, 主要计算成本取决于步骤 S2.1, 或者更具体地, 求解子问题 (4.1). 下一小节应用黄金分割法求解子问题 (4.1).

算法 2 (3.1) 的坐标下降法

- S1 初始化: 初始点 x^0 , 误差 $\epsilon > 0$, $k := 0$. 选择一个顺序 (4.4) 或 (4.3), 记为 $\mathcal{O}$.
 S2 对于每一轮 k ,
 S2.0 按照 $\mathcal{O}$ 的顺序选择 j .
 S2.1 在 x_j^k , 通过 (4.1) 和 (4.2) 得到 x_j^{k+1} .
 S2.2 如果 $j == n$, 停止, 输出 x^{k+1} . 否则, 按照 $\mathcal{O}$ 的顺序选择 j , 转到 S2.1.
 S3 如果 $f(x^k) - f(x^{k+1}) < \epsilon$, 停止; 否则, $k := k + 1$, 转到 S2.
-

4.2 子问题 (4.1) 的黄金分割法

子问题 (4.1) 是具有简单界约束的一维最小化问题. 然而, 由于事实 (i), 不可能设计基于梯度的算法, 因此不能使用 Armijo 线搜索和 Wolfe-Powell 线搜索^[18] 等线搜索策略. 本文选用黄金分割法, 因为它只涉及函数值的计算. 黄金分割法最初由 Kiefer^[14] 提出, 并由我国著名数学家华罗庚^[12] 在中国推广. 它本质上是一种精确的线搜索方法, 也称为 0.618 方法, 能保证在单峰区间内找到局部极小值.

黄金分割法的另一个优点是, 该方法的思想是尝试使用尽可能少的函数计算. 这解决了挑战 (iii'). 此外, 黄金分割法的搜索间隔被压缩为固定比率 0.618, 直到获得近似的局部极小值. 注意, 黄金分割法需要在单峰区间内应用. 下面首先讨论如何使用进退法获得单峰区间, 然后介绍黄金分割法的细节.

4.2.1 第一步: 找到单峰区间

为了找到单峰区间, 一种典型的方法是进退法^[16]. 之所以选择这种方法, 是因为它只涉及函数值计算, 这完全解决了挑战 (i'). 然而, 在应用进退法时, 必须确保间隔介于 d_j 和 c_j 之间. 换句话讲, 概率不能超出区域 $[d_j, c_j]$. 因此, 对进退法进行了以下修正.

- 当使用步长进行正向搜索时, 转移概率 x_j 可能超过 c_j . 在这种情形下, 缩小步长并重新进行搜索.
- 当以步长向后移动时, 转移概率 x_j 可能会降低到 d_j . 在这种情形下, 也缩小步长并重新进行搜索.

注 4.1 通过上述修改, 可以保证单峰区间是区间 $[d_j, c_j]$ 的子集. 通过应用进退法, (4.1) 中的界约束自动满足.

针对挑战 (ii), 子问题 (4.1) 也可能存在多个局部极小值. 所以, 对于 x_j , 在 $[d_j, c_j]$ 中可能存在多个单峰区间, 每个区间可能包含一个局部极小值. 因此, 我们使用以下策略试图找到尽可能多的单峰区间.

令 z 为已有的经验转移概率. 可以合理地假设转移概率在 z 的 $\pm 20\%$ 区间内. 因此, 将初始间隔设置为 $z_j \pm 0.2z_j$. 对于每个区间 $[0.8z_j, 1.2z_j]$, 从中选取了 q 个定位点, 并将它们分别设置为进退法的起点. 然后, 将得到至多 q 个单峰区间, 表示为 $[l_{j_i}, u_{j_i}]$ ($i = 1, 2, \dots, q$), 用于表示 $[0.8z_j, 1.2z_j]$ 内的单峰间隔.

4.2.2 第二步: 黄金分割法

对于进退法返回的每个单峰区间 $[l_{j_i}, u_{j_i}]$, 子问题 (4.1) 简化为以下问题:

$$\min_{y_j \in [l_{j_i}, u_{j_i}]} g^{h,j}(y_j). \quad (4.5)$$

因此, 可以直接应用黄金分割法, 其细节如算法 3 所示.

注意, 对于每个 y_j , 进退法至多得到 q 个区间. 对于每个区间 $[l_{j_i}, u_{j_i}]$, 可以应用算法 3 来获得子问题 (4.5) 的局部极小值, 表示为 $y_{j_i}^{h+1}$ ($i = 1, 2, \dots, q$). 然后选择对应最小函数值的一个, 即令

$$y_j^{h+1} = \arg \min_{i \in \{1, 2, \dots, q\}} \{g^{h,j}(y_{j_i}^h)\}. \quad (4.6)$$

相应的单峰区间表示为 $[l_{j_{\min}}, u_{j_{\min}}]$.

注 4.2 每个 j 的区间 c 将在后面的第 5 节中用于推导出每个转移概率的概率分布中的参数.

算法 3 (4.5) 的黄金分割法

- S0 初始化: 单峰区间 $[a_1, b_1]$, 其中 $a_1 = l_{j_i}$, $b_1 = u_{j_i}$, $\epsilon_g > 0$, $g(\cdot) := g^{h,j}(\cdot)$, $l := 0$.
 S1 计算试验点 $\lambda_1 = a_1 + 0.382(b_1 - a_1)$, $\mu_1 = a_1 + 0.618(b_1 - a_1)$ 和 $g_1 = g(\lambda_1)$, $g_2 = g(\mu_1)$.
 S2 如果 $b_l - a_l < \epsilon_g$, 停止. 否则, 如果 $g_1 > g_2$, 则转到 S3; 如果 $g_1 \leq g_2$, 则转到 S4.
 S3 令 $a_{l+1} = \lambda_l$, $b_{l+1} = b_l$, $\lambda_{l+1} = \mu_l$, $\mu_{l+1} = a_{l+1} + 0.382(b_{l+1} - a_{l+1})$, $g_1 := g_2$. 计算 $g_2 = g(\mu_{l+1})$, 转到 S5.
 S4 令 $a_{l+1} = a_l$, $b_{l+1} = \mu_l$, $\mu_{l+1} = \lambda_l$, $\lambda_{l+1} = a_{l+1} + 0.382(b_{l+1} - a_{l+1})$, $g_2 := g_1$. 计算 $g_1 = g(\lambda_{l+1})$, 转到 S5.
 S5 令 $l := l + 1$, 转到 S2.

算法 4 子问题 (4.1) 的黄金分割法

- S0 给定 y^h 和索引 j .
 S1 通过进退法求单峰区间 $[l_{j_i}, u_{j_i}]$ ($i = 1, 2, \dots, q$).
 S2 对于每个区间 $[l_{j_i}, u_{j_i}]$, 用算法 3 求解子问题 (4.5) 得到 $y_{j_i}^{h+1}$ ($i = 1, 2, \dots, q$).
 S3 由 (4.6) 和 (4.2) 得到 y^{h+1} .

最后, 算法 4 给出了求解子问题 (4.1) 的黄金分割法.

总而言之, 我们用坐标下降法 (算法 2) 求解优化问题 (3.30), 用黄金分割法 (算法 4) 求解子问题 (4.1). 所得方法称为基于黄金分割的坐标下降法 (golden section based coordinate descent method, GSCD).

5 确定 Beta 分布参数的最佳拟合规则

本节假设每个转移概率 x_i 是一个随机变量, 遵循 Beta 分布 $B(w_i, v_i)$ ($i = 1, 2, \dots, n$). 文献 [23] 中也使用了类似假设. 我们需要找到每个 Beta 分布 $B(w_i, v_i)$ ($i = 1, 2, \dots, n$) 的参数 (w_i, v_i) .

令第 4 节中 GSCD 给出的解为 x^* . 我们合理地假设 x_j 的期望值为 x_j^* , 即

$$E(x_j) = x_j^*. \quad (5.1)$$

还要注意, $B(w_j, v_j)$ 的期望值可以通过 $\frac{w_j}{w_j + v_j}$ 计算. 结合 (5.1), 有

$$\frac{w_j}{w_j + v_j} = x_j^*. \quad (5.2)$$

此外, 可以合理地假设一个数字越接近 x_j^* , 它作为 x_j 在 Beta 分布中的转移概率发生的可能性就越大. 也就是说, 具有一定可信度的置信区间可能与区间 $[l_{j_{\min}}, u_{j_{\min}}]$ 有一定的重叠. 因此, 令两个区间的重叠比例记为 ρ . 例如, ρ 可以选择为 95%. 然后可以找到 (w_j, v_j) 使得所得到的 Beta 分布与单峰区间有最佳匹配. 再根据 (5.2), 可以得到 (w_j, v_j) . 该方法称为最佳匹配方法 (best matching method, BMM), 见算法 5.

算法 5 最佳匹配方法 (BMM)

- S0 初始化: $j = 1$.
 S1 以 x_j^* 为中点, 通过以下方式使区间 $[l_{j_{\min}}, u_{j_{\min}}]$ 对称, 得到 $[l_j, u_j]$. 如果 $l_{j_{\min}} \leq u_{j_{\min}}$, 令 $(l_j, u_j) := (l_{j_{\min}}, 2x_j^* - l_{j_{\min}})$, 否则, $(l_j, u_j) := (2x_j^* - u_{j_{\min}}, u_{j_{\min}})$.
 S2 找到 (w_i, v_i) 使得 (5.2) 成立并且 $[l_j, u_j]$ 是相应 Beta 分布的 95% 置信区间.
 S3 $j := j + 1$. 转到 S1.

注 5.1 在 S2 中, 选择 $w = 10 : 10 : 6 \times 10^6$, 然后对每个 w_j , 通过已知的 x_j^* 找到 v_j , 如果区间 $[l_j, u_j]$ 和 (w_i, v_i) 有至少 95% 的重合度, 则保存结果; 否则, 我们使用固定概率 x_j^* .

注 5.2 我们想强调的是, 在第 4 和 5 节中所提出的方法也适用于每一年各个状态间转移概率都有变化的情形, 并可扩展到估计其他转移概率, 如其他原因导致的死亡率和从临床前期到相应临床期的转移概率.

6 数值结果

本节以不同的方式测试本文的模型 (3.1) 以及本文所提出的方法 GSCD. 所有测试均在装有 Windows 10 64 位和 RAM 4GB 的笔记本电脑上的 MATLAB R2020a 中进行. 在我们的模拟中, 设置 $Y_1 = 20$, $Y_2 = 89$, $r = 10^5$. 选择起始点 x^0 作为转移概率, 如表 5 所示. 对于假设 3.2 和 3.3 中的固定转移概率, 同样参见表 5. 对于 λ_i , 将其选择为 $\lambda_i = \frac{1}{3}$ ($i = 1, 2, 3$), 因为来自 IR 、 MR 和 PC 三部分的损失对函数值的贡献相等.

6.1 GSCD 的性能

为了测试我们的方法 GSCD, 需要选择几个参数, 如损失函数 $L(\cdot)$ 、每个子问题中的单峰区间数以及坐标下降法中更新块的顺序. 选择两个损失函数分别为 l_2 损失函数 $l_2(x) = \|x\|_2^2$ 和 l_1 损失函数 $l_1(x) = \|x\|_1$. 对于每个子问题中的区间数, 选择 $q = 1, 2, \dots, 10$. 对于更新 x 中块的顺序, 我们比较自然升序 $\mathcal{O}_1$ 和特殊顺序 $\mathcal{O}_2$. 我们从以下 3 个方面评估性能: 函数值、函数计算次数以及以秒为单位的时间.

首先, 测试 GSCD 以选择适当的更新顺序和单峰区间数, 结果如表 6 和 7 所示. 从表 6 和 7 中可以看出, 对于固定损失函数和间隔数, 在大多数情形下, 按自然升序 $\mathcal{O}_1$ 更新的函数值大于特殊顺序 $\mathcal{O}_2$ (以粗体标记) 更新的函数值. 而对于区间数, 如果它较大, 则表示要找到更多的单峰区间, 这提供了更多机会达到子问题 (4.1) 的全局最小值. 然而, 区间数大也代表大量的函数值计算. 这可以通过表 6 和 7 中的函数计算次数进行验证. 在固定的更新顺序下, 随着 q 的增加, 函数计算的次数逐渐增加, 并且时间相应变长.

对于不同区间数中, $q = 4$ (用下划线标记) 是 l_2 损失函数的最佳选择, 因为它提供了最小的函数值 $f = 1.0709$ 以及合理次数的函数计算 (小于 100,000 次). 对于 l_1 损失函数, 间隔数 $q = 4$ (用下划线标记) 也导致函数值最小, 函数计算次数为 70,188. 由于上述分析, 在下面的测试中, 选择特殊顺序 $\mathcal{O}_2$ 来更新 x 中的分量, 并且 q 取 4.

6.2 与无导数方法的比较

本小节将我们的方法与无导数方法包 (即 pdfo (www.pdfo.net), 包括 BOBYQA^[19] 和 LINCOA^[20]) 进行比较. LINCOA^[20] 是一种用于求解具有约束的非线性问题的无导数方法, 其迭代都是可行点. BOBYQA^[19] 与 LINCOA 类似, 但在更新过程中涉及不可行点, BOBYQA 返回的解决方案是可行的. 我们运行了几轮 LINCOA 和 BOBYQA. 例如, 在 LINCOA 成功终止后, 我们将输出 x^k 作为 LINCOA 的起点, 并重新启动它, 直到目标函数几乎没有进展. 所得方法分别表示为 mLINCOA 和 mBOBYQA. 3 种方法的结果如表 8 所示. 可以观察到, GSCD 证明了 l_2 损失函数在实现最小函数值方面的优越性能, 并且仅用略多于一半 mLINCOA 的用时. 虽然 mBOBYQA 速度快, 但其函数值太大. 对于以 l_1 为

表 5 各状态的转移概率 [17]

年龄	概率									
	健康 ↪ 临床前小 叶原位癌	健康 ↪ 临床前导 管原位癌	临床前小 叶原位癌 ↪ 临床前 I 期	临床前小 叶原位癌 ↪ 临床前 II 期	临床前 II 期 ↪ 临床前 III 期	I 期 ↪ 死于乳腺癌	II 期 ↪ 死于乳腺癌	III 期 ↪ 死于乳腺癌	IV 期 ↪ 死于乳腺癌	死于其 他原因
20~24	0.00002	0.00010	0.3108	0.259	0.12	0.010	0.016	0.045	0.115	0.00012
25~29	5.5E-05	0.00031	0.3108	0.259	0.12	0.010	0.016	0.045	0.115	0.00025
30~34	6.3E-05	0.00035	0.3108	0.259	0.12	0.010	0.016	0.045	0.115	0.00033
35~39	0.00019	0.00103	0.3108	0.259	0.12	0.010	0.016	0.045	0.115	0.00037
40~44	0.00014	0.00079	0.3108	0.259	0.12	0.010	0.016	0.045	0.115	0.00066
45~49	0.00022	0.00122	0.3348	0.279	0.08	0.004	0.011	0.038	0.108	0.00102
50~54	0.00006	0.00037	0.3348	0.279	0.08	0.004	0.011	0.038	0.108	0.00254
55~59	0.00028	0.00150	0.3588	0.299	0.08	0.004	0.008	0.035	0.131	0.00237
60~64	0.00005	0.00025	0.3388	0.279	0.08	0.002	0.007	0.034	0.131	0.00631
65~69	0.00015	0.00083	0.3348	0.279	0.08	0.002	0.006	0.033	0.130	0.01045
70~74	0.00010	0.00058	0.3348	0.279	0.08	0.003	0.009	0.036	0.137	0.01616
75~79	0.00011	0.00063	0.3348	0.279	0.08	0.003	0.009	0.045	0.157	0.02901
80~84	1.4E-05	0.00008	0.3348	0.279	0.08	0.006	0.013	0.049	0.160	0.06526
85~89	1.1E-05	0.00006	0.3348	0.279	0.08	0.014	0.022	0.060	0.180	0.15990

年龄	概率									
	临床前 I 期 ↪ 临床前 II 期	临床前 III 期 ↪ 临床前 IV 期	原位癌 ↪ 死于乳腺癌	原位癌 ↪ 可发现乳腺癌	I 期 ↪ 可发现乳腺癌	II 期 ↪ 可发现乳腺癌	III 期 ↪ 可发现乳腺癌	IV 期 ↪ 可发现乳腺癌		
20~89	0.2200	0.1300	0.0005	0.0110	0.0510	0.1790	0.7100	0.8200		

表中概率大部分经过大量文献检索遴选得到, 部分经过微调.

表 6 具有 l_2 损失函数的 GSCD 的数值结果 ($\cdot|\cdot$ 表示 $\mathcal{O}_1|\mathcal{O}_2$)

区间数	函数值	函数计算次数	时间 (s)
1	20,386.7790 20,458.6870	15,948 15,812	56.4655 43.9741
2	1.8619 1.3121	34,386 34,714	115.1541 96.5898
3	1.5223 2.4156	52,539 52,730	160.1719 144.9383
4	1.9769 1.0709	70,193 69,885	203.0923 <u>194.2593</u>
5	3.5665 1.8640	87,902 87,323	256.5255 240.3513
6	3.2901 1.3382	104,648 104,858	337.6391 289.2767
7	2.0163 2.4472	121,973 122,466	400.1538 337.4090
8	3.4260 1.8444	139,888 138,788	581.4621 381.3832
9	2.5902 2.2415	158,542 158,338	650.9977 437.3446
10	2.5403 2.5935	174,555 175,184	545.5852 483.3577

表 7 具有 l_1 损失函数的 GSCD 的数值结果 ($\cdot|\cdot$ 表示 $\mathcal{O}_1|\mathcal{O}_2$)

区间数	函数值	函数计算次数	时间 (s)
1	364.0350 364.1569	15,845 16,034	45.4367 44.7706
2	2.9116 4.0278	34,765 27,839	97.9811 79.0576
3	6.1225 5.5540	52,384 52,356	145.2791 147.4834
4	5.3767 2.1396	69,723 <u>70,188</u>	194.4973 <u>196.4294</u>
5	6.0809 3.1873	87,381 87,393	243.5753 244.6787
6	5.0213 7.1979	104,334 104,389	335.0704 290.6722
7	5.1326 6.5793	122,782 122,342	346.3706 342.9791
8	4.5715 3.1358	139,943 139,793	401.2845 390.8526
9	5.3746 2.7422	159,928 158,713	447.4998 442.7415
10	4.1951 4.9593	174,348 174,568	485.6807 488.9925

表 8 与无导数方法的比较: 多轮, $\cdot|\cdot$ 表示 l_1 损失 | l_2 损失

方法	函数值	函数计算次数	时间 (s)
GSCD	1.0709 2.1396	69,885 70,188	335.6287 339.1583
mLINCOA	1.4839 4.9266	98,948 101,739	591.4297 599.5412
mBOBYQA	129.5973 19.6610	2038 2374	11.7693 13.8608

损失函数的对比结果, GSCD 非常具有竞争力, 因为它实现的函数值最小. 它只使用了 mLINCOA 消耗的大约一半的时间. 同样, mBOBYQA 的函数值仍然很大.

综上所述, 表 8 中的结果表明, 我们专门设计的 GSCD 在解决问题 (3.1) 方面的表现要优于无导数求解器 LINCOA 和 BOBYQA.

6.3 由 BMM 获得分布

最后, 根据 GSCD 和 GSCD 获得的转移概率运行 BMM. 根据 GSCD 中返回的平均值 x^* , 运行 BMM 的时间在表 9 中给出. 可以观察到, 与表 8 中的结果相比, 确定转移概率的分布比寻找最佳匹配转移概率 x^* 花费的时间要少得多. 主要原因是 BMM 没有涉及函数计算. 转移概率的分布可用于

表 9 GSCD 返回的平均值 x^* 计算 BMM 的时间

x^*	l_2 损失下的时间 (s)	l_1 损失下的时间 (s)
GSCD	52	36

每个转移概率的进一步敏感性分析. 此外, 它还可用于通过更复杂的方法进一步寻找更好的转移概率. 注意, 对于无导数方法, 它们因为没有每个转移概率的区间信息, 所以不能用于获得转移概率的分布.

7 结论

本文提出了一种优化模型, 用于在不使用样本数据的情形下估计中国特定的乳腺癌自然史中的参数. 本文提出了一种以黄金分割法为子求解器的坐标下降法来求解该模型, 其目标没有明确的公式. 数值结果表明该模型和所提出的方法非常有效. 此外, 本文的方法是在 MATLAB 中实现的, 并且独立于 MISCAN 和 TreeAge 等现有平台. 基于所提出的方法, 可以对筛查模型进行进一步的扩展以及成本效益分析, 这是我们未来将要研究的工作.

参考文献

1 Blumenson L E, Bross I D J. A mathematical analysis of the growth and spread of breast cancer. *Biometrics*, 1969, 25: 95–109

2 Bross I D J, Blumenson L E, Slack N H, et al. A two disease model for breast cancer. In: *Prognostic Factors in Breast Cancer*. Edinburgh: E. & S. Livingstone Ltd, 1968, 288–300

3 Chen H H, Duffy S W, Tabar L. A Markov chain method to estimate the Tumour progression rate from preclinical to clinical phase, sensitivity and positive predictive value for mammography in breast cancer screening. *J R Stat Soc Ser D Statist*, 1996, 45: 307–317

4 Chen Y, Brock G, Wu D. Estimating key parameters in periodic breast cancer screening—Application to the Canadian National Breast Screening Study data. *Cancer Epidemiol*, 2010, 34: 429–433

5 Conn A R, Scheinberg K, Vicente L N. *Introduction to Derivative-Free Optimization*. MOS-SIAM Series on Optimization. Philadelphia: SIAM, 2009

6 Dai M, Shi J F, Li N. The design and expectation of the cancer screening program in urban China (in Chinese). *Zhonghua Yufang Yixue Zazhi*, 2013, 47: 179–182 [代敏, 石菊芳, 李霓. 中国城市癌症早诊早治项目设计及预期目标. *中华预防医学杂志*, 2013, 47: 179–182]

7 Eddy D M. *Screening for Cancer: Theory, Analysis, and Design*. Englewood Cliffs: Prentice Hall, 1980

8 Eddy D M, Shwartz M. Mathematical models in screening. In: *Cancer Epidemiology and Prevention*. New York: Oxford University Press, 1982, 1075–1090

9 Ferlay J, Soerjomataram I, Dikshit R, et al. Cancer incidence and mortality worldwide: Sources, methods and major patterns in GLOBOCAN 2012. *Int J Cancer*, 2015, 136: E359–E386

10 Gunsoy N B, Garcia-Closas M, Moss S M. Modelling the overdiagnosis of breast cancer due to mammography screening in women aged 40 to 49 in the United Kingdom. *Breast Cancer Res*, 2012, 14: 1–10

11 Habbema J D F, van Oortmarssen G J, Lubbe J T N, et al. The MISCAN simulation program for the evaluation of screening for disease. *Comput Methods Programs Biomed*, 1984, 20: 79–93

12 Hua L G. *Methods of Optimal Selection* (in Chinese). Beijing: Science Press, 1981 [华罗庚. 优选学. 北京: 科学出版社, 1981]

13 Hunter D J W, Drake S M, Shortt S E D, et al. Simulation modeling of change to breast cancer detection age eligibility recommendations in Ontario, 2002–2021. *Cancer Detection Prevention*, 2004, 28: 453–460

14 Kiefer J. Sequential minimax search for a maximum. *Proc Amer Math Soc*, 1953, 4: 502–506

15 Knox E G. A simulation system for screening procedures. In: *The Future and Present Indicatives*. London: Nuffield Provincial Hospitals Trust, 1973, 19–55

16 Li X W, Yan G F, Li Q N. *Optimization Methods* (in Chinese). Beijing: Beijing Institute of Technology Publisher, 2018 [李学文, 闫桂峰, 李庆娜. 最优化方法. 北京: 北京理工大学出版社, 2018]

17 Ma H M, Wang L, Shi J F, et al. A systematic review of international simulation models on the natural history of breast cancer: Current understanding and challenges for Chinese—Population-specific model development (in Chinese). *Chinese J Epidemiol*, 2017, 38: 1419–1425 [马恒敏, 王乐, 石菊芳, 等. 乳腺癌自然史模型研究系统评价: 现状及构

- 建中国人群特异性模型面临的挑战. 中华流行病学杂志, 2017, 38: 1419–1425]
- 18 Nocedal J, Wright S J. Numerical Optimization, 2nd ed. New York: Springer, 2006
 - 19 Powell M J D. The BOBYQA Algorithm for Bound Constrained Optimization Without Derivatives. Report DAMTP 2009/NA06. Cambridge: Cambridge University, 2009
 - 20 Powell M J D. On fast trust region methods for quadratic models with linear constraints. Math Program Comput, 2015, 7: 237–267
 - 21 Rijnsburger A J, van Oortmarssen G J, Boer R, et al. Mammography benefit in the Canadian National Breast Screening Study-2: A model evaluation. Int J Cancer, 2004, 110: 756–762
 - 22 Rosenquist C J, Lindfors K K. Screening mammography beginning at age 40 years: A reappraisal of cost-effectiveness. Cancer, 1998, 82: 2235–2240
 - 23 Schiller-Fruehwirth I, Jahn B, Einzinger P, et al. The long-term effectiveness and cost effectiveness of organized versus opportunistic screening for breast cancer in Austria. Value Health, 2017, 20: 1048–1057
 - 24 Shapiro S, Venet W, Strax P, et al. Ten- to fourteen-year effect of screening on breast cancer mortality. J Natl Cancer Inst, 1982, 69: 349–355
 - 25 Shwartz M. A mathematical model used to analyze breast cancer screening strategies. Oper Res, 1978, 26: 937–955
 - 26 Tsunematsu M, Kakehashi M. An analysis of mass screening strategies using a mathematical model: Comparison of breast cancer screening in Japan and the United States. J Epidemiol, 2015, 25: 162–171
 - 27 Van Oortmarssen G J, Habbema J D F, Van Der Maas P J, et al. A model for breast cancer screening. Cancer, 1990, 66: 1601–1612
 - 28 Wang L, Zhang Y, Shi J F, et al. Disease burden of female breast cancer in China (in Chinese). Chinese J Epidemiol, 2016, 37: 970–976 [王乐, 张玥, 石菊芳, 等. 中国女性乳腺癌疾病负担分析. 中华流行病学杂志, 2016, 37: 970–976]
 - 29 Wright S J. Coordinate descent algorithms. Math Program, 2015, 151: 3–34
 - 30 Yen M F, Tabár L, Vitak B, et al. Quantifying the potential problem of overdiagnosis of ductal carcinoma *in situ* in breast cancer screening. Eur J Cancer, 2003, 39: 1746–1754
 - 31 Zelen M. A hypothesis for the natural time history of breast cancer. Cancer Res, 1968, 28: 207–216

An optimization approach for parameter selection in natural history of breast cancer in China

Juan Yin, Le Wang, Xiaoning Bai, Yanjie Li, Xin Wang, Zaikun Zhang, Bingzhao Li, Yang Li, Jufang Shi & Qingna Li

Abstract Breast cancer is one of the most common cancers for females. In order to propose efficient screening strategies and evaluate the effect, one fundamental and important step is to choose proper parameters, i.e., transition rates, in the natural history model of breast cancer in China. There are two challenges to choosing reasonable transition rates. Firstly, the transition rates used in other countries may be not applicable to China, due to the cancer epidemiology. Secondly, little screening sample data are available, making the traditional statistical based approaches such as maximum likelihood methods fail. In this paper, we propose an optimization approach for parameter selection in the natural history of breast cancer in China. A mathematical optimization model is established based on the published statistical data. A coordinate descent algorithm is proposed to solve the resulting box-constrained and highly nonlinear problem, whose objective function does not have an explicit form. Finally, the best matching method is proposed to estimate the distributions of each transition rate. Our approach provides solid foundations to further propose reasonable screening strategies for breast cancer in China and analyze the economic burden of breast cancer.

Keywords breast cancer, natural history, parameter selection, golden section methods, derivative-free methods, coordinate descent methods

MSC(2020) 90C56, 90C26, 90C10

doi: 10.1360/SCM-2022-0196